

多元统计分析

广义线性模型 (GLM) 数学理论与 R 语言实现

邹文杰

2026 年 4 月

哈尔滨商业大学

01 一般线性模型回顾

数学定义、基本假设与局限性

02 GLM 理论部分

定义、指数族分布、核心定理、三要素
解析

03 GLM 标准化建模流程

数学步骤与实操流程

04 二项分布 GLM 实例

逻辑回归·数学模型·R 代码·结果解读

05 泊松分布 GLM 实例

计数回归·数学模型·R 代码·结果解读

06 课程总结

理论梳理与方法归纳

一般线性模型回顾

一般线性模型：数学定义与假设

定义一般线性模型

设独立观测 $(Y_i, X_{i1}, \dots, X_{ip})$, 模型形式为:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip} + \varepsilon_i$$

矩阵形式: $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$

基本假设 (Gauss-Markov)

- 线性性: $\mathbb{E}(Y) = \mathbf{X}\beta$
- 正态性: $\varepsilon_i \sim N(0, \sigma^2)$, 即 $Y | X \sim N(\mu, \sigma^2)$
- 方差齐性: $\text{Var}(Y) = \sigma^2$ (常数)
- 独立性: ε_i 相互独立

核心局限

仅适用于**连续正态数据**, 无法处理二分类/计数/偏态数据

GLM 理论部分

指数族分布

定义单参数指数族
概率分布可表示为：

$$f(y; \theta, \phi) = \exp \left\{ \frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right\}$$

- θ ：自然参数 (决定均值)
- ϕ ：离散参数 (方差)
- $b(\theta)$ ：累积量函数，满足 $\mathbb{E}(Y) = b'(\theta)$, $\text{Var}(Y) = a(\phi)b''(\theta)$

常见指数族分布

正态分布、二项分布、泊松分布、伽马分布均属于指数族

广义线性模型 (GLM)

定义 GLM 的定义

广义线性模型 (GLM) 是满足以下条件的统计模型:

1. 响应变量 $Y_1, \dots, Y_n$ 独立且服从**指数族分布**
2. 存在严格单调可微函数 $g(\cdot)$, 使得

$$g(\mathbb{E}(\mathbf{Y})) = \eta = \mathbf{X}\beta = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$$

其中: η 为**线性预测子**, β 为待估参数向量, g 为**连接函数**

定义典则连接

若取 $\eta = g(\mu) = \theta$, 其中 θ 为指数族分布中的自然参数, 则称这样的 g 为**典则连接**

注

连接函数的作用: 将受限均值映射为全体实数

g 的逆变换 $g^{-1}(\eta)$ 一般要具有实际意义, 例如: 优势比、发生率。

定理 OLS 是 GLM 的特例

当 $Y | X \sim N(\mu, \sigma^2)$ 且连接函数 $g(\mu) = \mu$ 时, GLM 退化为一般线性模型

定理参数估计

GLM 参数采用**最大似然估计** (MLE), 通过迭代加权**最小二乘** (IRLS) 求解:

$$\hat{\beta} \xrightarrow{d} N(\beta, (X^T W X)^{-1})$$

具有一致性、渐近正态性

关键性质

GLM 不要求方差齐性, 方差 $\text{Var}(Y) = V(\mu)$ 是均值的函数

GLM 标准化建模流程

GLM 建模全流程 (数学 + 实操)

Step 1 数据判定

判定 Y 的分布类型。例如：连续 $\rightarrow$ 正态；二分类 $\rightarrow$ 二项；计数 $\rightarrow$ 泊松

Step 2 模型设定

选定分布 + 连接函数，构建 $g(\mu) = \mathbf{X}\beta$ ，然后确定 GLM 数学表达式

Step 3 参数估计

MLE+IRLS 迭代求解 $\hat{\beta}$ 。R 语言 `glm()` 函数拟合

Step 4 模型检验

显著性检验、AIC、偏差检验。例如：P 值 < 0.05 为显著，AIC 越小拟合越好

Step 5 预测与解释

逆变换 $\mu = g^{-1}(\eta)$ 还原均值。例如：概率/计数预测，优势比/发生率比解读

二项分布 GLM: 逻辑回归

二项 GLM: 数学模型与理论

定义二项分布 GLM

- 随机部分: $Y_i \sim \text{Binomial}(1, \pi)$, $\pi = \mathbb{E}(Y)$
- 连接函数: Logit 典则连接

$$g(\pi) = \text{logit}(\pi) = \ln \left(\frac{\pi}{1 - \pi} \right)$$

- 模型公式: $\ln \left(\frac{\pi}{1 - \pi} \right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$

逆变换 (预测)

$$\pi = \frac{\exp(\mathbf{X}\beta)}{1 + \exp(\mathbf{X}\beta)} \in (0, 1)$$

实例：研究生录取预测•R 代码 (tidyverse)

数据与建模

R 代码

```
1 # 加载tidyverse包
2 library(tidyverse)
3 # 读取UCLA录取数据
4 df <- read_csv("https://stats.idre.ucla.edu/stat/data/binary.csv")
5 # 数据预处理
6 df <- df %>% mutate(rank = factor(rank))
7 # 拟合二项(GLM逻辑回归)
8 model_bin <- glm(admit ~ gre + gpa + rank,
9 data = df, family = binomial(link = "logit"))
10 # 模型结果
11 summary(model_bin)
```

模型结果

```
Call:
glm(formula = admit ~ gre + gpa + rank, family = binomial(link = "logit"),
    data = df)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-3.989979	1.139951	-3.500	0.000465	***
gre	0.002264	0.001094	2.070	0.038465	*
gpa	0.804038	0.331819	2.423	0.015388	*
rank2	-0.675443	0.316490	-2.134	0.032829	*
rank3	-1.340204	0.345306	-3.881	0.000104	***
rank4	-1.551464	0.417832	-3.713	0.000205	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 499.98 on 399 degrees of freedom
Residual deviance: 458.52 on 394 degrees of freedom
AIC: 470.52

Number of Fisher Scoring iterations: 4

广义线性模型 (逻辑回归) 结果解释

系数显著性检验

截距、gre、gpa、rank2、rank3、rank4 均通过显著性检验 ($P < 0.05$), 所有变量对录取结果均有显著影响

最终回归模型 (Logit 形式)

$$\begin{aligned}\text{logit}(\hat{p}) &= \ln \left(\frac{\hat{p}}{1 - \hat{p}} \right) \\ &= -3.99 + 0.00226 \text{ gre} + 0.804 \text{ gpa} - 0.675 \text{ rank2} - 1.340 \text{ rank3} - 1.551 \text{ rank4}\end{aligned}$$

其中 $\hat{p}$ 表示考生被录取的概率。

优势比 (OR) 解释

优势比 (OR) 解释

优势比公式:

$$OR_j = \exp(\beta_j)$$

- $OR(gre) = 1.002$: GRE 分数每增加 1 分, 录取优势扩大为原来的 1.002 倍
- $OR(gpa) = 2.23$: GPA 每提升 1 分, 录取优势扩大为原来的 2.23 倍
- $OR(rank2) = 0.51$: rank2 院校考生的录取优势为 rank1 的 51%
- $OR(rank3) = 0.26$: rank3 院校考生的录取优势为 rank1 的 26%
- $OR(rank4) = 0.21$: rank4 院校考生的录取优势为 rank1 的 21%

模型拟合评价

- 零偏差: 499.98 ($df = 399$), 残差偏差: 458.52 ($df = 394$), 偏差差 $\Delta Deviance = 41.46$, 自由度差 $df = 5$, 整体显著 ($p < 0.001$)
- 离散参数 (残差偏差/零偏差) 近似为 1, 无严重过离散问题, 模型设定合理

注

零偏差 (Null deviance): 只有截距项的模型的偏差 (完全不用自变量, 只用样本均值预测)。

残差偏差 (Residual deviance): 当前模型的偏差, 代表模型无法解释的部分。

残差偏差 < 零偏差说明模型确实解释了一部分变量。

泊松分布 GLM: 计数回归

定义泊松分布 GLM

- 随机部分: $Y_i \sim \text{Poisson}(\lambda)$, $\lambda = \mathbb{E}(Y) > 0$
- 连接函数: 对数典则连接

$$g(\lambda) = \ln(\lambda)$$

- 模型公式: $\ln(\lambda) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$

逆变换

$$\lambda = \exp(\mathbf{X}\beta) > 0$$

实例：织布断线次数分析•R 代码 (tidyverse)

数据与建模

R 代码

```
1 library(tidyverse)
2 # 加载R内置断线数据
3 data(warpbreaks)
4 # 拟合泊松GLM
5 model_pois <- glm(breaks ~ wool + tension,
6 data = warpbreaks, family = poisson(link = "log"))
7 # 模型结果
8 summary(model_pois)
9 # 计算发生率比IRR
10 exp(coef(model_pois))# coef()提取回归系数
```

模型结果

```
Call:
glm(formula = breaks ~ wool + tension, family = poisson(link = "log"),
     data = warpbreaks)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   3.69196     0.04541  81.302 < 2e-16 ***
woolB         -0.20599     0.05157  -3.994 6.49e-05 ***
tensionM      -0.32132     0.06027  -5.332 9.73e-08 ***
tensionH      -0.51849     0.06396  -8.107 5.21e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

    Null deviance: 297.37  on 53  degrees of freedom
Residual deviance: 210.39  on 50  degrees of freedom
AIC: 493.06

Number of Fisher Scoring iterations: 4

(Intercept)      woolB      tensionM      tensionH
40.1235380      0.8138425      0.7251908      0.5954198
```

泊松回归模型公式 (Log 连接)

$$\log(\lambda) = 3.692 - 0.206 \text{ woolB} - 0.321 \text{ tensionM} - 0.518 \text{ tensionH}$$

其中 $\lambda = E(\text{breaks})$ 为断线次数的期望；- wool 以 A 类纱线为基准组，B 类为哑变量；- tension 以低张力 (L) 为基准组，中/高张力为哑变量。

系数显著性检验

所有变量系数的 P 值均小于 0.001，表明：wool 类型与 tension 张力水平对断线次数均有极显著影响。

发生率比 (IRR) 解释

泊松回归中，发生率比 (Incidence Rate Ratio) 公式为：

$$IRR_j = \exp(\beta_j)$$

表示自变量每变化 1 单位，事件发生率变为原来的倍数：

- $IRR(\text{woolB}) = 0.81$ ：B 类纱线的断线发生率为 A 类的 81%，即减少约 19%
- $IRR(\text{tensionM}) = 0.73$ ：中张力下断线发生率为低张力的 73%，即减少约 27%
- $IRR(\text{tensionH}) = 0.60$ ：高张力下断线发生率为低张力的 60%，即减少约 40%

模型拟合评价

- 零偏差：297.37 ($df = 53$)，残差偏差：210.39 ($df = 50$)，偏差差 $\Delta\text{Deviance} = 86.98$ ，自由度差 $df = 3$ ，整体显著 ($p < 0.001$)
- 离散参数 (残差偏差/零偏差) 近似为 1，无严重过离散问题，模型设定合理

课程总结

GLM 核心理论

- 基于指数族分布，突破正态假设
- 连接函数完成均值 $\rightarrow$ 线性预测子映射
- OLS 是 GLM 的特例
- MLE 估计，IRLS 求解

核心结论

GLM 是线性模型的公理级拓展，是处理非正态数据的标准统计方法

两大经典模型

- 二分类数据：二项 GLM+logit 连接 $\rightarrow$ 逻辑回归
- 计数数据：泊松 GLM+log 连接 $\rightarrow$ 计数回归
- 统一用 `glm()` 实现

感谢观看

THANKS FOR WATCHING