

多元统计分析

广义线性模型 (GLM) 数学理论与 R 语言实现

邹文杰

2026 年 4 月

哈尔滨商业大学

01 一般线性模型回顾

数学定义、基本假设与局限性

02 GLM 理论部分

定义、指数族分布、核心定理、三要素
解析

03 GLM 标准化建模流程

数学步骤与实操流程

04 二项分布 GLM 实例

逻辑回归 · 数学模型 · R 代码 · 结果解读

05 泊松分布 GLM 实例

计数回归 · 数学模型 · R 代码 · 结果解读

06 课程总结

理论梳理与方法归纳

一般线性模型回顾

一般线性模型：数学定义与假设

定义一般线性模型

设独立观测 $(Y_i, X_{i1}, \dots, X_{ip})$ ，模型形式为：

$$Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip} + \varepsilon_i$$

矩阵形式： $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$

基本假设 (Gauss-Markov)

- 线性性： $\mathbb{E}(Y) = \mathbf{X}\beta$
- 正态性： $\varepsilon_i \sim N(0, \sigma^2)$ ，即 $Y | X \sim N(\mu, \sigma^2)$
- 方差齐性： $\text{Var}(Y) = \sigma^2$ (常数)
- 独立性： ε_i 相互独立

核心局限

仅适用于连续正态数据，无法处理二分类/计数/偏态数据

GLM 理论部分

指数族分布

定义单参数指数族
概率分布可表示为:

$$f(y; \theta, \phi) = \exp \left\{ \frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right\}$$

- θ : 自然参数 (决定均值)
- ϕ : 离散参数 (方差)
- $b(\theta)$: 累积量函数, 满足 $\mathbb{E}(Y) = b'(\theta)$, $\text{Var}(Y) = a(\phi)b''(\theta)$

常见指数族分布

正态分布、二项分布、泊松分布、伽马分布均属于指数族

广义线性模型 (GLM)

定义 GLM 的定义

广义线性模型 (GLM) 是满足以下条件的统计模型：

1. 响应变量 $Y_1, \dots, Y_n$ 独立且服从指数族分布
2. 存在严格单调可微函数 $g(\cdot)$ ，使得

$$g(\mathbb{E}(Y)) = \eta = \mathbf{X}\beta = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$$

其中： η 为线性预测子， β 为待估参数向量， g 为连接函数

定义典则连接

若取 $\eta = g(\mu) = \theta$ ，其中 θ 为指数族分布中的自然参数，则称这样的 g 为典则连接

注

连接函数的作用：将受限均值映射为全体实数

g 的逆变换 $g^{-1}(\eta)$ 一般要具有实际意义，例如：优势比、发生率。

定理 OLS 是 GLM 的特例

当 $Y|X \sim N(\mu, \sigma^2)$ 且连接函数 $g(\mu) = \mu$ 时, GLM 退化为一般线性模型

定理参数估计

GLM 参数采用最大似然估计 (MLE), 通过迭代加权最小二乘 (IRLS) 求解:

$$\hat{\beta} \xrightarrow{d} N(\beta, (X^T W X)^{-1})$$

具有一致性、渐近正态性

关键性质

GLM 不要求方差齐性, 方差 $\text{Var}(Y) = V(\mu)$ 是均值的函数

GLM 标准化建模流程

GLM 建模全流程 (数学 + 实操)

Step 1 数据判定

判定 Y 的分布类型。例如：连续 $\rightarrow$ 正态；二分类 $\rightarrow$ 二项；计数 $\rightarrow$ 泊松

Step 2 模型设定

选定分布 + 连接函数，构建 $g(\mu) = \mathbf{X}\beta$ ，然后确定 GLM 数学表达式

Step 3 参数估计

MLE+IRLS 迭代求解 $\hat{\beta}$ 。R 语言 `glm()` 函数拟合

Step 4 模型检验

显著性检验、AIC、偏差检验。例如：P 值 < 0.05 为显著，AIC 越小拟合越好

Step 5 预测与解释

逆变换 $\mu = g^{-1}(\eta)$ 还原均值。例如：概率/计数预测，优势比/发生率比解读

二项分布 GLM: 逻辑回归

二项 GLM：数学模型与理论

定义二项分布 GLM

- 随机部分： $Y_i \sim \text{Binomial}(1, \pi)$, $\pi = \mathbb{E}(Y)$
- 连接函数：Logit 典则连接

$$g(\pi) = \text{logit}(\pi) = \ln \left(\frac{\pi}{1 - \pi} \right)$$

- 模型公式： $\ln \left(\frac{\pi}{1 - \pi} \right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$

逆变换 (预测)

$$\pi = \frac{\exp(\mathbf{X}\beta)}{1 + \exp(\mathbf{X}\beta)} \in (0, 1)$$

实例：研究生录取预测 · R 代码 (tidyverse)

数据与建模

R 代码

```
1 # 加载tidyverse包
2 library(tidyverse)
3 # 读取UCLA录取数据
4 df <- read_csv("https://stats.idre.ucla.edu/stat/data/binary.csv")
5 # 数据预处理
6 df <- df %>% mutate(rank = factor(rank))
7 # 拟合二项(GLM逻辑回)归
8 model_bin <- glm(admit ~ gre + gpa + rank,
9 data = df, family = binomial(link = "logit"))
10 # 模型结果
11 summary(model_bin)
```

模型结果

```
Call:
glm(formula = admit ~ gre + gpa + rank, family = binomial(link = "logit"),
    data = df)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-3.989979	1.139951	-3.500	0.000465	***
gre	0.002264	0.001094	2.070	0.038465	*
gpa	0.804038	0.331819	2.423	0.015388	*
rank2	-0.675443	0.316490	-2.134	0.032829	*
rank3	-1.340204	0.345306	-3.881	0.000104	***
rank4	-1.551464	0.417832	-3.713	0.000205	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 499.98 on 399 degrees of freedom
Residual deviance: 458.52 on 394 degrees of freedom
AIC: 470.52

Number of Fisher Scoring iterations: 4

广义线性模型 (逻辑回归) 结果解释

系数显著性检验

截距、gre、gpa、rank2、rank3、rank4 均通过显著性检验 ($P < 0.05$), 所有变量对录取结果均有显著影响

最终回归模型 (Logit 形式)

$$\begin{aligned}\text{logit}(\hat{p}) &= \ln \left(\frac{\hat{p}}{1 - \hat{p}} \right) \\ &= -3.99 + 0.00226 \text{ gre} + 0.804 \text{ gpa} - 0.675 \text{ rank2} - 1.340 \text{ rank3} - 1.551 \text{ rank4}\end{aligned}$$

其中 $\hat{p}$ 表示考生被录取的概率。

优势比 (OR) 解释

优势比 (OR) 解释

优势比公式：

$$OR_j = \exp(\beta_j)$$

- $OR(\text{gre}) = 1.002$: GRE 分数每增加 1 分, 录取优势扩大为原来的 1.002 倍
- $OR(\text{gpa}) = 2.23$: GPA 每提升 1 分, 录取优势扩大为原来的 2.23 倍
- $OR(\text{rank2}) = 0.51$: rank2 院校考生的录取优势为 rank1 的 51%
- $OR(\text{rank3}) = 0.26$: rank3 院校考生的录取优势为 rank1 的 26%
- $OR(\text{rank4}) = 0.21$: rank4 院校考生的录取优势为 rank1 的 21%

模型拟合评价

- 零偏差: 499.98 ($df = 399$), 残差偏差: 458.52 ($df = 394$), 偏差差 $\Delta Deviance = 41.46$, 自由度差 $df = 5$, 整体显著 ($p < 0.001$)
- 离散参数 (残差偏差/零偏差) 近似为 1, 无严重过离散问题, 模型设定合理

注

零偏差 (Null deviance): 只有截距项的模型的偏差 (完全不用自变量, 只用样本均值预测)。

残差偏差 (Residual deviance): 当前模型的偏差, 代表模型无法解释的部分。

残差偏差 $<$ 零偏差说明模型确实解释了一部分变量。

泊松分布 GLM: 计数回归

定义泊松分布 GLM

- 随机部分： $Y_i \sim \text{Poisson}(\lambda)$, $\lambda = \mathbb{E}(Y) > 0$
- 连接函数：对数典则连接

$$g(\lambda) = \ln(\lambda)$$

- 模型公式： $\ln(\lambda) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$

逆变换

$$\lambda = \exp(\mathbf{X}\beta) > 0$$

实例：织布断线次数分析 · R 代码 (tidyverse)

数据与建模

R 代码

```
1 library(tidyverse)
2 # 加载R内置断线数据
3 data(warpbreaks)
4 # 拟合泊松GLM
5 model_pois <- glm(breaks ~ wool + tension,
6 data = warpbreaks, family = poisson(link = "log"))
7 # 模型结果
8 summary(model_pois)
9 # 计算发生率比IRR
10 exp(coef(model_pois)) # coef()提取回归系数
```

```
Call:
glm(formula = breaks ~ wool + tension, family = poisson(link = "log"),
     data = warpbreaks)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   3.69196     0.04541  81.302 < 2e-16 ***
woolB         -0.20599     0.05157  -3.994 6.49e-05 ***
tensionM      -0.32132     0.06027  -5.332 9.73e-08 ***
tensionH      -0.51849     0.06396  -8.107 5.21e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

    Null deviance: 297.37  on 53  degrees of freedom
Residual deviance: 210.39  on 50  degrees of freedom
AIC: 493.06

Number of Fisher Scoring iterations: 4

(Intercept)      woolB      tensionM      tensionH
40.1235380    0.8138425    0.7251908    0.5954198
```

结果解读与模型解释 (泊松回归)

泊松回归模型公式 (Log 连接)

$$\log(\lambda) = 3.692 - 0.206 \text{ woolB} - 0.321 \text{ tensionM} - 0.518 \text{ tensionH}$$

其中 $\lambda = E(\text{breaks})$ 为断线次数的期望；- wool 以 A 类纱线为基准组，B 类为哑变量；- tension 以低张力 (L) 为基准组，中/高张力为哑变量。

系数显著性检验

所有变量系数的 P 值均小于 0.001，表明：wool 类型与 tension 张力水平对断线次数均有极显著影响。

发生率比 (IRR) 解释

泊松回归中，发生率比 (Incidence Rate Ratio) 公式为：

$$IRR_j = \exp(\beta_j)$$

表示自变量每变化 1 单位，事件发生率变为原来的倍数：

- $IRR(\text{woolB}) = 0.81$ ：B 类纱线的断线发生率为 A 类的 81%，即减少约 19%
- $IRR(\text{tensionM}) = 0.73$ ：中张力下断线发生率为低张力的 73%，即减少约 27%
- $IRR(\text{tensionH}) = 0.60$ ：高张力下断线发生率为低张力的 60%，即减少约 40%

模型拟合评价

- 零偏差：297.37 (df = 53)，残差偏差：210.39 (df = 50)，偏差差 $\Delta\text{Deviance} = 86.98$ ，自由度差 df = 3，整体显著 ($p < 0.001$)
- 离散参数 (残差偏差/零偏差) 近似为 1，无严重过离散问题，模型设定合理

课程总结

GLM 核心理论

- 基于指数族分布，突破正态假设
- 连接函数完成均值 $\rightarrow$ 线性预测子映射
- OLS 是 GLM 的特例
- MLE 估计，IRLS 求解

核心结论

GLM 是线性模型的公理级拓展，是处理非正态数据的标准统计方法

两大经典模型

- 二分类数据：二项 GLM+logit 连接 $\rightarrow$ 逻辑回归
- 计数数据：泊松 GLM+log 连接 $\rightarrow$ 计数回归
- 统一用 `glm()` 实现

感谢观看

THANKS FOR WATCHING