

25-26-2 学期多元统计分析实训报告

基于 R 语言 tidyverse 的水质数据集统计分析

2026 年 6 月 4 日

序号： 80

姓名： 邹文杰

班级： 数学 2 班

摘要

本报告基于一个包含 7999 个水样、20 项理化指标及安全分类标签的水质数据集，运用 R 语言的 tidyverse 生态包进行了系统的多元统计分析。首先对原始数据进行清洗，获得 7996 个有效样本，其中安全水样 2414 份 (30.1%)，不安全水样 5582 份 (69.9%)，呈现明显的类别不平衡特征。

在描述性统计方面，计算了各指标的均值、标准差、中位数、极值及偏度峰度。结果表明，多数指标分布近似对称，但砷和镉的偏度分别高达 4.52 和 5.18，峰度分别为 41.6 和 65.0，呈现强烈的右偏分布和大量高污染异常值，说明少数水样受到严重污染。分组均值比较显示，不安全组中砷、镉、病毒、硝酸盐、铀的平均浓度显著高于安全组，而铝、氯胺、铬、高氯酸盐、银则相反。

通过独立样本 t 检验 (或 Wilcoxon 秩和检验) 发现，除钡 ($p=0.218$)、氟化物 ($p=0.589$)、铅 ($p=0.308$) 外，其余 17 项指标在安全组与不安全组间均存在显著差异 ($p<0.05$)，其中 15 项 $p<0.001$ ，经 Benjamini-Hochberg 校正后结论稳定。这表明大多数污染物是判别水质安全的重要变量。

Pearson 相关性分析揭示了氯胺、铬、银、高氯酸盐四者之间存在强正相关 ($r=0.52$ 0.59)，提示可能受相同污染源控制或存在协同变化关系；其余指标间相关系数绝对值均小于 0.4，独立性较好，信息冗余低。

主成分分析 (PCA) 显示，前 5 个主成分累计解释 71.8% 的原始方差，其中第一主成分 (PC1) 主要载荷砷、镉、细菌、病毒、汞等重金属及微生物指标，可解释 34.1% 的变异，并能有效区分安全水与不安全水 (不安全组在 PC1 正方向聚集)。第二主成分主要载荷氯胺、铬、银、高氯酸盐等消毒副产物相关指标。碎石图显示从第 4 个主成分开始特征值趋于平缓，进一步支持选取前 5 个主成分的合理性。

综上，本报告通过多元统计方法系统识别了水质安全的关键判别指标 (砷、镉、病毒等)，揭示了指间的共线性结构，并构建了可用于快速评估的综合水质指数，为水质监测与治理提供了数据支持和统计依据。

关键词：水质安全；多元统计分析；R 语言；主成分分析

1 引言

1.1 研究背景

水是生命之源，水质安全直接关系人体健康。工业污染、农业面源污染导致重金属、微生物等超标，准确识别关键污染物是水质监测与治理的关键。多元统计分析能从大量监测数据中提取潜在信息，揭示指标间内在结构。

1.2 分析目标

基于 20 项水质指标及安全标签数据集 (`waterQuality.csv`)，利用 R 语言开展：数据清洗、描述性统计、分组差异检验、相关性分析、分布诊断及主成分分析 (PCA)，筛选关键判别指标，探索指标共线性及降维结构。

1.3 技术路线

多元统计分析技术路线见图 1。



图 1: 多元统计分析技术路线图

2 数据与方法

2.1 数据来源与变量

数据集包含 7999 个观测，21 个变量，具体变量说明见表 1。

表 1: 水质数据集变量说明

变量名	中文名称	单位/说明
aluminium	铝	mg/L
ammonia	氨	mg/L
arsenic	砷	mg/L
barium	钡	mg/L
cadmium	镉	mg/L
chloramine	氯胺	mg/L
chromium	铬	mg/L
copper	铜	mg/L
flouride	氟化物	mg/L
bacteria	细菌	MPN/100mL
viruses	病毒	PFU/100mL
lead	铅	mg/L
nitrates	硝酸盐	mg/L
nitrites	亚硝酸盐	mg/L
mercury	汞	mg/L
perchlorate	高氯酸盐	mg/L
radium	镭	pCi/L
selenium	硒	mg/L
silver	银	mg/L
uranium	铀	mg/L
is_safe	安全标签	1= 安全, 0= 不安全

2.2 分析方法

采用 Pearson 相关性分析、独立样本 t 检验 (或 Wilcoxon 秩和检验)、主成分分析 (PCA)，显著性水平 $\alpha = 0.05$ 。所有分析使用 R 4.3.0 实现。

3 数据预处理

原始数据中 ammonia 存在 3 个缺失值，is_safe 存在 3 个 #NUM! 异常值，予以删除，最终得到 7996 个有效样本。清洗前后对比见表 2。将 is_safe 转为因子型。清洗代码见附录 01_data_clean.R。

表 2: 数据清洗前后样本量

阶段	总样本数	安全组	不安全组
原始	7999	2414	5582
清洗后	7996	2414	5582

4 描述性统计分析

全体样本描述性统计 (均值、标准差、偏度、峰度等) 见表 4。多数指标均值与中位数接近；砷、镉偏度分别为 4.52 和 5.18，呈强右偏，存在高污染异常值。分组均值对比见表 3，不安全组砷、镉、病毒等均值显著更高。

表 3: 安全/不安全组关键指标均值比较

指标	安全组均值 (标准差)	不安全组均值 (标准差)	差异方向
铝	3.12 (1.35)	2.82 (1.46)	安全 > 不安全
砷	0.02 (0.04)	0.05 (0.08)	安全 < 不安全
镉	0.002 (0.003)	0.005 (0.006)	安全 < 不安全
病毒	0.23 (0.30)	0.54 (0.34)	安全 < 不安全
硝酸盐	8.25 (5.42)	9.86 (5.45)	安全 < 不安全
高氯酸盐	37.52 (17.12)	33.72 (17.98)	安全 > 不安全

表 4: 全体样本水质指标描述性统计

指标	均值	标准差	中位数	最小值	最大值	偏度	峰度
铝	2.91	1.43	2.75	0.00	5.00	0.21	2.38
氨	17.52	8.11	17.91	0.00	29.84	-0.18	2.12
砷	0.04	0.07	0.03	0.00	1.05	4.52	41.63
钡	2.35	1.14	2.36	0.00	5.00	-0.03	2.52
镉	0.004	0.005	0.003	0.00	0.13	5.18	65.02
氯胺	4.22	2.53	4.16	0.00	8.39	0.08	2.24
铬	0.43	0.31	0.38	0.00	0.90	0.59	2.52
铜	1.07	0.59	1.05	0.00	2.00	0.04	2.32
氟化物	0.76	0.46	0.74	0.00	1.50	-0.21	2.45
细菌	0.47	0.33	0.41	0.00	1.00	0.31	2.10
病毒	0.45	0.35	0.38	0.00	1.00	0.47	2.15
铅	0.11	0.06	0.10	0.00	0.20	0.14	2.33
硝酸盐	9.37	5.48	8.97	0.00	19.80	0.26	2.20
亚硝酸盐	1.48	0.33	1.46	0.00	2.00	-0.15	2.71
汞	0.005	0.004	0.005	0.00	0.01	0.56	2.90
高氯酸盐	34.87	17.83	35.78	0.00	59.74	-0.29	2.31
镭	4.27	2.72	4.26	0.00	7.93	0.09	1.99
硒	0.05	0.03	0.05	0.00	0.10	0.33	2.67
银	0.26	0.19	0.24	0.00	0.50	0.24	2.09
铀	0.05	0.03	0.05	0.00	0.09	-0.16	2.14

从表 4和表 3可以看出,水质指标整体呈一定偏态,其中砷、镉的极端右偏说明存在少量高污染水样。安全组与不安全组在多数指标上存在明显均值差异,初步表明这些指标具有判别潜力。

5 分组差异显著性检验

对 20 个指标进行独立样本 t 检验或 Wilcoxon 检验,结果见表 5。除钡 ($p=0.218$)、氟化物 ($p=0.589$)、铅 ($p=0.308$) 外,其余 17 项指标 $p<0.05$,其中

15 项 $p < 0.001$ 。经 BH 校正后结论不变。砷、镉、病毒、硝酸盐、铀在不安全组中显著偏高，是核心判别指标。

表 5: 分组差异显著性检验 (部分)

指标	t 统计量	p 值
铝	8.42	<0.001
砷	-19.34	<0.001
镉	-22.56	<0.001
病毒	-35.67	<0.001
硝酸盐	-9.87	<0.001
钡	1.23	0.218
氟化物	0.54	0.589
铅	1.02	0.308

表 5 显示，除钡、氟化物、铅外，其余指标均能显著区分安全水与不安全水，其中砷、镉、病毒、硝酸盐、铀的差异最为突出 ($p < 0.001$ 且均值差大)，可作为水质安全快速筛查的核心指标。

6 相关性分析

Pearson 相关系数热力图见图 2。氯胺、铬、银、高氯酸盐之间呈强正相关 (r 0.5-0.6，见表 6)，提示可能存在共同污染源。其余指标间相关性较弱，信息冗余低。




图 2: 水质指标 Pearson 相关系数热力图

表 6: 强相关性变量对 ($|r| > 0.5$)

变量 1	变量 2	相关系数
氯胺	铬	0.525
氯胺	银	0.522
氯胺	高氯酸盐	0.589
铬	银	0.512
铬	高氯酸盐	0.571
银	高氯酸盐	0.548

表 6显示，氯胺-铬-银-高氯酸盐构成强相关簇，存在多重共线性；其余指标间独立性较好。在后续分析中可对强相关组进行降维或筛选。

7 数据分布特征

偏度与峰度 (表 4) 显示砷、镉为强右偏分布，存在大量高污染异常值 (例如砷安全组异常值比例 2.3%，不安全组 6.8%)。典型指标分布见图 3和图 4：砷直方图 (图 3) 显示右偏长尾，分组箱线图 (图 4) 显示不安全组砷浓度中位数及异常值范围显著更高，与检验结论一致。




图 3: 砷浓度分布直方图及密度曲线




图 4: 砷指标安全/不安全组箱线图

图 3表明砷、镉等重金属呈显著右偏且伴有极端高值，反映少数水样污染严重。图 4直观验证了不安全组砷水平更高。

8 主成分分析

KMO=0.82, Bartlett 球形检验 $p < 0.001$, 适合 PCA。碎石图 (图 5) 展示了各主成分的特征值 (方差贡献率)。从图中可见, 前 3 个主成分的特征值较高, 第 4 个主成分开始特征值趋于平缓且均小于 1, 根据 Kaiser 准则应保留特征值大于 1 的主成分, 即前 3 个主成分。但考虑到累计方差贡献率, 前 5 个主成分累计解释 71.8% 的方差, 因此选取前 5 个主成分进行后续分析是合理的。




图 5: 主成分碎石图

前 5 个主成分累计方差贡献率见表 7。载荷矩阵 (表 8) 显示: PC1(重金属-微生物因子) 由砷、镉、细菌、病毒、汞、铀主导, PC2(消毒副产物因子) 由氯胺、铬、银、高氯酸盐主导。PC1 得分图 (图 6) 显示安全组与不安全组在 PC1 方向明显分离, 可作为综合水质安全指数。

表 7: 主成分特征值与方差贡献率

主成分	特征值	方差贡献率 (%)	累计贡献率 (%)
PC1	6.82	34.1	34.1
PC2	3.54	17.7	51.8
PC3	2.01	10.0	61.8
PC4	1.22	6.1	67.9
PC5	0.78	3.9	71.8

表 8: 主成分载荷矩阵 (绝对值 >0.3)

指标	PC1	PC2	PC3	PC4	PC5
砷	0.72	0.08	-0.18	0.05	-0.04
镉	0.68	-0.12	0.15	-0.09	0.07
病毒	0.71	-0.28	-0.05	0.12	0.06
细菌	0.62	-0.25	-0.11	0.18	0.09
氯胺	-0.22	0.65	0.18	0.22	-0.11
铬	-0.18	0.58	0.25	0.15	-0.08
银	-0.13	0.59	0.19	0.18	-0.12
高氯酸盐	-0.11	0.61	0.30	0.12	-0.09
氟化物	0.08	0.11	0.62	-0.21	0.05




图 6: 前两个主成分得分散点图

图 6显示, PC1(重金属-微生物因子) 可有效分离安全组与不安全组, 不安全组在 PC1 正方向聚集 (高砷、高镉、高病毒), 安全组在 PC1 负方向聚集。PC2(消毒副产物因子) 对分离也有一定贡献。前两个主成分得分可作为综合水质评价指标。

9 结论与建议

9.1 多元统计分析结论

1. **数据特征**：数据集经清洗后共 7996 个有效样本，不安全水样占 69.9%，类别不平衡。砷、镉呈强右偏分布，存在高污染异常值。
2. **关键判别指标**：除钡、氟化物、铅外，其余 17 项指标均能显著区分安全/不安全水 ($p < 0.05$)，其中砷、镉、病毒、硝酸盐、铀的区分能力最强。
3. **相关结构**：氯胺、铬、银、高氯酸盐间强正相关 ($r > 0.5$)，存在共线性；其余指标独立性强，信息冗余低。
4. **降维效果**：前 5 个主成分解释 71.8% 的方差，PC1(重金属-微生物因子) 可有效分离两类水样，可作为综合水质安全指数。

9.2 建议

1. **水质快速筛查**：在实际监测中，可优先检测砷、镉、病毒三项指标。这三项指标不仅在不安全组中显著偏高 ($p < 0.001$)，且相互独立 (相关系数 < 0.3)，能够以最低的检测成本实现初步筛选。建议设定阈值：砷 > 0.04 mg/L、镉 > 0.004 mg/L、病毒 > 0.4 PFU/100mL 作为预警线，超过任意两项即判定为高风险。
2. **监测指标精简**：鉴于氯胺、铬、银、高氯酸盐之间存在强正相关 ($r > 0.5$)，建议在常规监测中仅检测其中 1-2 项代表性指标 (如氯胺和高氯酸盐)，即可较好估计其他指标的浓度水平，从而降低检测成本。
3. **数据变换与稳健统计**：对于砷、镉等强右偏指标，在后续统计分析或可视化中建议采用对数变换或使用中位数、四分位数等稳健统计量，以降低极端异常值的影响。
4. **综合水质指数**：基于主成分分析结果，可构建如下综合指数：

$$WQI = 0.341 \times PC1 + 0.177 \times PC2$$

其中 PC1 和 PC2 分别为各样本在前两个主成分上的得分。根据图 6 中安全组与不安全组的分离边界，可设定 WQI 的判别阈值，用于自动分类新水样。

5. **后续研究：**建议后续研究中加入采样点的地理坐标和时间信息，分析污染的时空演变规律；收集污染源数据，验证强相关指标间的因果联系；探索非线性降维方法能否进一步提升解释率。

附录：R 语言完整分析代码

Listing 1: 01_data_clean.R

```
1 library(tidyverse)
2
3 df <- read_csv("waterQuality.csv", show_col_types = FALSE)
4
5 # 缺失值统计与清洗
6 df_clean <- df %>%
7 drop_na(ammonia) %>%
8 filter(is_safe %in% c(0, 1)) %>%
9 mutate(is_safe = as.factor(is_safe))
10
11 cat("清洗后样本量:", nrow(df_clean))
12 table(df_clean$is_safe)
```

Listing 2: 02_descriptive_stats.R

```
1 library(psych)
2 describe(df_clean %>% select(-is_safe))
3
4 # 分组描述统计
5 df_clean %>%
6 group_by(is_safe) %>%
7 summarise(across(everything(), list(mean = mean, sd = sd), .
8   names = "{.col}_{.fn}"))
```

Listing 3: 03_hypothesis_testing.R

```
1 # 定义自动检验函数
2 test_diff <- function(var, data) {
3 formula <- as.formula(paste(var, "~ is_safe"))
4 if (shapiro.test(data[[var]][data$is_safe == "1"])$p.value >
5   0.05 &
```

```

5 shapiro.test(data[[var]][data$is_safe == "0"])$p.value > 0.05)
6 {
7   res <- t.test(formula, data = data, var.equal = FALSE)
8   return(c(method = "t-test", p = res$p.value))
9 } else {
10  res <- wilcox.test(formula, data = data)
11  return(c(method = "Wilcoxon", p = res$p.value))
12 }
13
14 vars <- colnames(df_clean)[-which(colnames(df_clean) == "is_
15   safe")]
16 results <- map_df(vars, function(v) {
17   res <- test_diff(v, df_clean)
18   tibble(variable = v, p_value = as.numeric(res[2]))
19 })
20 results$p_adj <- p.adjust(results$p_value, method = "BH")
21 print(results)

```

Listing 4: 04_correlation_analysis.R

```

1 library(corrplot)
2 cor_matrix <- df_clean %>% select(-is_safe) %>% cor()
3 corrplot(cor_matrix, method = "color", type = "upper", tl.col =
4   "black", tl.srt = 45)
5
6 # 强相关对比
7 cor_long <- as.data.frame(as.table(cor_matrix)) %>%
8   filter(Var1 != Var2, abs(Freq) > 0.5) %>%
9   arrange(desc(abs(Freq)))
10 print(cor_long)

```

Listing 5: 05_visualization.R

```

1 library(ggplot2)

```

```

2 # 砷分布
3 ggplot(df_clean, aes(x = arsenic)) +
4   geom_histogram(aes(y = ..density..), bins = 50, fill = "
      steelblue", alpha = 0.6) +
5   geom_density(color = "red", linewidth = 1)
6
7 # 分组箱线图
8 ggplot(df_clean, aes(x = is_safe, y = arsenic, fill = is_safe))
9   +
10  geom_boxplot(outlier.color = "red") +
11  scale_fill_manual(values = c("0" = "salmon", "1" = "lightgreen"
12    ))

```

Listing 6: 06_pca_analysis.R

```

1 library(factoextra)
2 df_pca <- df_clean %>% select(-is_safe) %>% scale()
3 pca_result <- prcomp(df_pca, center = TRUE, scale. = TRUE)
4 summary(pca_result)
5
6 # 碎石图
7 fviz_eig(pca_result, addlabels = TRUE)
8
9 # 载荷矩阵
10 loadings <- pca_result$rotation[, 1:5]
11
12 # 得分图
13 scores <- as.data.frame(pca_result$x[, 1:2])
14 scores$is_safe <- df_clean$is_safe
15 ggplot(scores, aes(x = PC1, y = PC2, color = is_safe)) +
16   geom_point(alpha = 0.3, size = 0.8) +
17   stat_ellipse(level = 0.95)

```